Misurazione Implicita in Psicologia:
Un approccio diverso per l'analisi dei dati IAT

Ottavia M. Epifania
University of Trento
ottavia.epifania@unitn.it

Master di II livello in Psicologia quantitativa

11 Settembre 2026

Struttura Fully-Crossed

12 stimoli target

White people faces

Black people faces

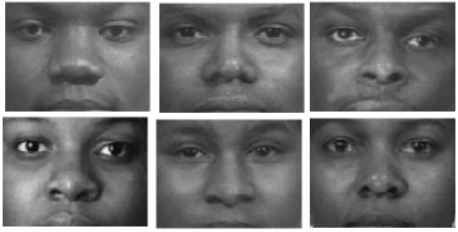

16 stimoli attributo

Attributi positivi

Good, laughter, pleasure, glory, peace, happy, joy, love

Attributi negativi

Evil, bad, horrible, terrible, nasty, pain, failure, hate

Implicit Association Test

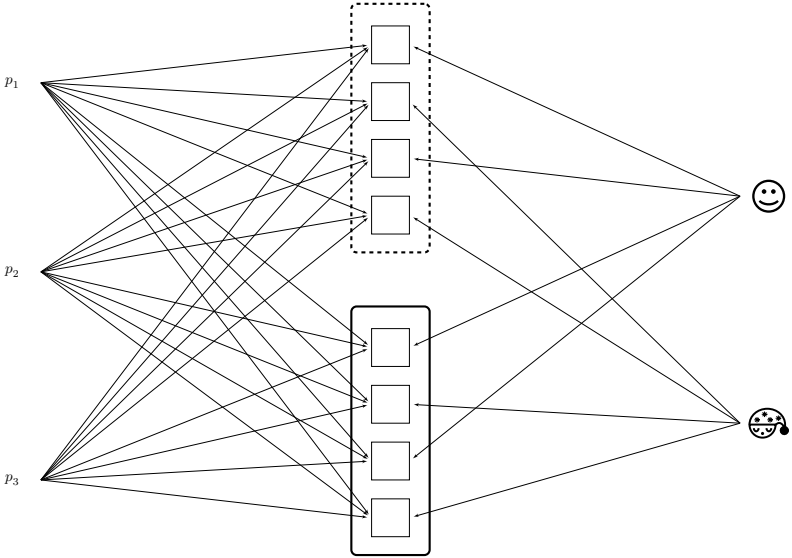

Person-level scores

$$s_p = \frac{\bar{X}_{p,\text{comp}} - \bar{X}_{p,\text{inc}}}{sd_{\text{pooled}}}$$

Person-level scores

$$s_p = \frac{\bar{X}_{p,\text{comp}} - \bar{X}_{p,\text{inc}}}{sd_{\text{pooled}}}$$

Vantaggi

Facile da calcolare
Facile da interpretare

Person-level scores

$$s_p = \frac{\bar{X}_{p,\text{comp}} - \bar{X}_{p,\text{inc}}}{sd_{\text{pooled}}}$$

Vantaggi

Facile da calcolare
Facile da interpretare

Assunzioni Implicite

1. Essere lenti (o meno accurati) in una condizione EQUIVALE ad essere veloci (o più accurati) nell'altra condizione: 0 implica assenza di preferenza/bias
2. Tutti gli stimoli hanno lo stesso effetto sulle risposte

I rispondenti sono fattori random

Campione prelevato da una popolazione più ampia
È necessario riconoscere la variabilità del campionamento
I risultati possono essere generalizzati ad altri rispondenti appartenenti alla stessa popolazione

Gli stimoli sono fattori fissi

Presi come intera popolazione
Non c'è variabilità del campionamento
Non è necessario generalizzare i risultati perché gli stimoli sono la popolazione

Generalizzabilità

La generalizzabilità è limitata al set specifico di stimoli utilizzato nell'esperimento
I risultati possono essere generalizzati se e solo se viene utilizzato esattamente lo stesso set di stimoli

Robustezza dei risultati

La variabilità casuale a livello degli stimoli potrebbe aumentare la probabilità di commettere errori di Tipo I
La media degli stimoli per ottenere punteggi a livello di persona porta a stime distorte a causa del rumore nei dati

Perdita di informazione

Non viene considerata tutta la variabilità né tutte le informazioni che possono essere ottenute da essa
Ogni stimolo è considerato come se fosse ugualmente informativo

Una possibile soluzione

Σ

Permette di tenere in considerazione la variabilità che si può incontrare a vari livelli, partizionando la varianza d'errore

Modelli lineari a effetti misti

ψ

Permette di dare un'interpretazione di tipo psicometrico sia al comportamento delle persone sia al funzionamento degli stimoli

Modello di Rasch

Una possibile soluzione

Σ

Permette di tenere in considerazione la variabilità che si può incontrare a vari livelli, partizionando la varianza d'errore

Modelli lineari a effetti misti

ψ

Permette di dare un'interpretazione di tipo psicometrico sia al comportamento delle persone sia al funzionamento degli stimoli

Modello di Rasch

Parametrizzazione di tipo Rasch ottenuta con l'applicazione del modelli lineari a effetti misti

When?

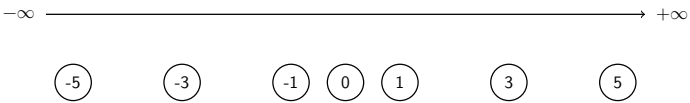

Numeri piccoli:
Percepiti a sinistra

Numeri ampi:
Percepiti a destra

Un *campione* di numeri piccoli:
$$1, 2, 3, 4$$

Un *campione* di numeri grandi:
$$6, 7, 8, 9$$

Due condizioni

La condizione "naturale" (*compatibile*)

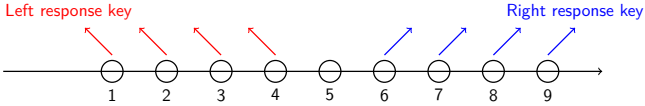

Un *campione* di numeri piccoli:
$$1, 2, 3, 4$$

Un *campione* di numeri grandi:
$$6, 7, 8, 9$$

Due condizioni

La condizione "naturale" (*compatibile*)

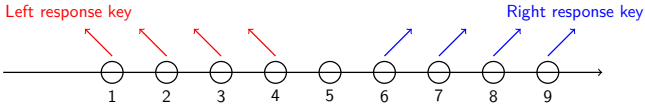

La condizione "innaturale" (*incompatibile*)

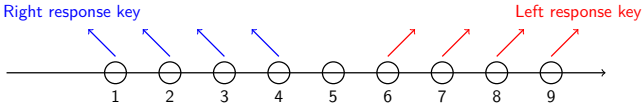

When?

Differenze a livewllo del campione:
Il senso di compatibile e incompatibile può essere definito a priori, *può non variare da persona a persona*
(SNARC effect)

Differenze Individuali:
Il senso di compatibile e incompatibile *può variare da persona a persona*
(Implicit Association Test)

$$\psi$$

Il modello di Rasch

$$P(x_{ps} = 1|\theta_p, b_s) = \frac{\exp(\theta_p - b_s)}{1 + \exp(\theta_p - b_s)}$$

θ_p: Livello del tratto latente della persona p {Maggiore è il valore, più alta è l'abilità}

b_s: Potere "sfidante" dello stimolo s {Maggiore è il valore, più alta è la difficoltà}

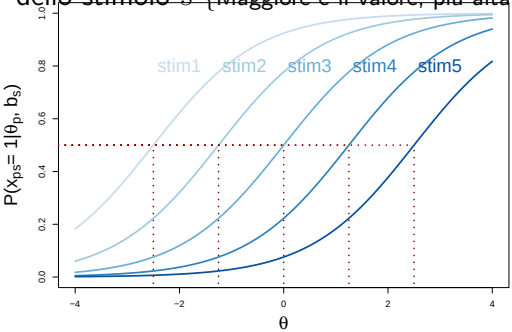

Il modello log-normale

$$E(t_{ps}|\tau_p, \delta_s) = \delta_s - \tau_p + \varepsilon$$

τ_p: La velocità della persona p nello svolgere il compito {Maggiore è il valore, più p è veloce}

δ_s: La time intensity dello stimolo s (ovvero il tempo che ogni stimoli richiede prima di ottenere una risposta) {Maggiore è il valore, maggiore è il tempo richiesto dallo stimolo s}

Σ

Modello Generalizzato Lineare (GLM)

Risposte dicotomiche 0 vs. 1

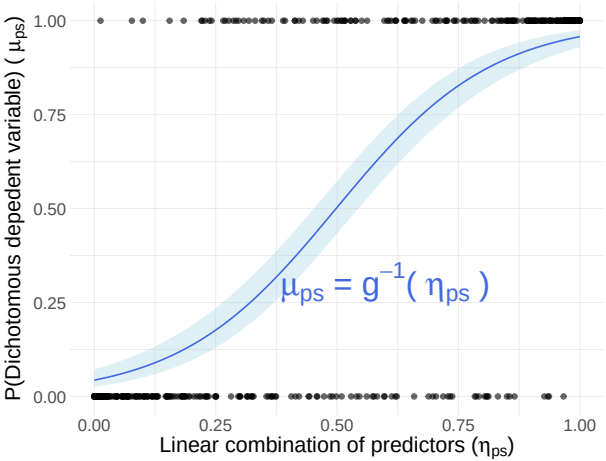

Funzione logit g:

$$g(\eta_{ps}) = log\left(\frac{\mu_{ps}}{1-\mu_{ps}}\right)$$

Funzione inversa del logit link: g^{-1}

$$g^{-1} = \frac{\exp(\eta_{ps})}{1+\exp(\eta_{ps})}$$

Rasch (ψ)

$$P(x_{ps} = 1) = \frac{\exp(\theta_p - b_s)}{1 + \exp(\theta_p - b_s)}$$

GLM (inverse function) (Σ)

$$P(x_{ps} = 1) = \frac{\exp(\theta_p + b_s)}{1 + \exp(\theta_p + b_s)}$$

Rasch (ψ)

$$P(x_{ps} = 1) = \frac{\exp(\theta_p - b_s)}{1 + \exp(\theta_p - b_s)}$$

GLM (inverse function) (Σ)

$$P(x_{ps} = 1) = \frac{\exp(\theta_p + b_s)}{1 + \exp(\theta_p + b_s)}$$

Interpetazione di b_s

Maggiore è il valore di b_s, più lo stimolo è facile

Log-normal (ψ)

$$E(t_{ps}|\tau_p, \delta_s) = \delta_s - \tau_p + \varepsilon$$

LM (Funzione di identità) ($Sigma$)

$$E(t_{ps}|\tau_p, \delta_s) = \delta_s + \tau_p + \varepsilon$$

Interpetazione di τ_p

Maggiore è il valore di τ_p, più la persona è lenta a rispondere

Fattori ed effetti random

In un modello lineare:

$$\eta = \mathbf{X}\beta$$

$\mathbf{X}$: Model Matrix

β: Coefficienti associati ai predittori specificati nella model matrix

In un modello lineare:

$$\eta = \mathbf{X}\beta$$

$\mathbf{X}$: Model Matrix

β: Coefficienti associati ai predittori specificati nella model matrix

Estensione per includere i fattori random:

$$\eta = \mathbf{X}\beta + Zd$$

d: Effetti random associati ai fattori random in Z ... Non sono parametri del modello! *Best Linear Unbiased Predictors*

Γ: Parametri stimati per i fattori random del modello (matrici di varianza-covarianza)

Maximal Model

Considera tutte le possibili sorgenti di variabilità che ha senso aspettarsi data una determinata struttura dei dati
Teoricamente, è il migliore

Maximal Model

Considera tutte le possibili sorgenti di variabilità che ha senso aspettarsi data una determinata struttura dei dati
Teoricamente, è il migliore

In pratica:

Meglio considerare i modelli che sono maggiormente utili dati gli obietivi della ricerca

Maximal Model

Considera tutte le possibili sorgenti di variabilità che ha senso aspettarsi data una determinata struttura dei dati
Teoricamente, è il migliore

In pratica:

Meglio considerare i modelli che sono maggiormente utili dati gli obietivi della ricerca

- Obiettivo più comune:
  Investigare i cambiamenti nella perfomance delle persone tra le condizioni associative

Maximal Model

Considera tutte le possibili sorgenti di variabilità che ha senso aspettarsi data una determinata struttura dei dati
Teoricamente, è il migliore

In pratica:

Meglio considerare i modelli che sono maggiormente utili dati gli obietivi della ricerca

- Obiettivo più comune:
  Investigare i cambiamenti nella perfomance delle persone tra le condizioni associative
- Obiettivo meno comune:
  Investigare i cambiamenti nel funzionamento degli stimoli tra le condizioni associative

Indice	Significato	Variabile
$p = 1, \dots, P$	Partecipante	`respondents`
$s = 1, \dots, S$	Stimoloi	`stimuli`
$c \in \{0, 1\}$	Condizione Associativa	`condition`
i	Trial	

Accuaratezze:
Modelli lineari generalizzati a effetti misti (GLMM)
$y = [0, 1]$

Log-tempi
Modelli lineari a effetti misti (LMM)
$y = (0, +\infty)$ (log-trasformati)

$$\varepsilon \sim \mathcal{N}(0, \sigma^2)$$

Modello 1:

$$y_i = \alpha + \beta_c X_c + \alpha_{p[i]} + \alpha_{s[i]} + \varepsilon_i$$

con

$\alpha_p \sim \mathcal{N}(0, \sigma_p^2)$ e $\alpha_s \sim \mathcal{N}(0, \sigma_s^2)$.

Modello 2:

$$y_i = \alpha + \beta_c X_c + \alpha_{p[i]} + \beta_{s[i]} c_i + \varepsilon_i$$

con $\alpha_p \sim \mathcal{N}(0, \sigma_p^2)$ e $\beta_s \sim \mathcal{MVN}(0, \Sigma_{sc})$.

Modello 3:

$$y_i = \alpha + \beta_c X_c + \alpha_{s[i]} + \beta_{p[i]} c_i + \varepsilon_i$$

con

$\alpha_s \sim \mathcal{N}(0, \sigma_s^2)$ e $\beta_p \sim \mathcal{MVN}(0, \Sigma_{pc})$.

Modello 1

Notazione

$$y = \beta_c X_c + \alpha_{p[i]} + \alpha_{s[i]}$$

lme4

```
y ~ 0 + condition + (1|stimuli) + (1|respondents)
```

Parametrizzazione Rasch-like

	GLMM	LMM
partecipanti	θ_p	τ_p
stimoli	b_s	δ_s

Modello 2

Notatione

$$y = \beta_c X_c + \alpha_{p[i]} + \beta_{s[i]} c_i$$

lme4

```
y ~ 0 + condition + (0+condition|stimuli) + (1|respondents)
```

Parametrizzazione Rasch-like

	GLMM	LMM
partecipanti	θ_p	τ_p
stimoli	b_{sc}	δ_{sc}

Modello 3

Notazione

$$y = \beta_c X_c + \beta_{p[i]} c_i + \alpha_{s[i]}$$

lme4

```
y ~ 0 + condition + (1|stimuli) + (0+condition|respondents)
```

Parametrizzazione Rasch-like

	GLMM	LMM
partecipanti	θ_{pc}	τ_{pc}
stimoli	b_s	δ_s

Summary

Models

Modello 1

$$y = \beta_c X_c + \alpha_{p[i]} + \alpha_{s[i]}$$

Modello 2

$$y = \beta_c X_c + \alpha_{p[i]} + \beta_{s[i]} c_i$$

Modello 3

$$y = \beta_c X_c + \beta_{p[i]} c_i + \alpha_{s[i]}$$

Parametrizations

	GLMM	LMM
	Model 1	
respondents	θ_p	τ_p
stimuli	b_s	δ_s
	Model 2	
respondents	θ_p	τ_p
stimuli	b_{sc}	δ_{sc}
	Model 3	
respondents	θ_{pc}	τ_{pc}
stimuli	b_s	δ_s

All models are wrong...

Il miglior modello viene trovato con model comparison, in particolare facendo riferimento all'Akaike's Information Criterion (AIC) e al Bayesian Information Criterion (BIC)

Sono indici di entropia: Penalizzano la verosimiglianza del modello per il numero di parametri

$$\text{AIC} = -2\ \log(\mathcal{L}) + 2k \qquad \text{BIC} = -2\ \log(\mathcal{L}) + k\ \log(n)$$

! AIC, BIC, e complessità

Il numero totale dei parametri è dato dalla somma dei parametri in β e in Γ
NON vengono contati i parametri in d

I modelli 2 e 3 hanno la stessa complessità, ma si concentrano su aspetti differenti del processo di risposta

Il modello scelto è il modello meno sbagliato *dati i modelli che vengono considerati*: Non è il modello migliore in assoluto

Dati reali

Coke
Good

Pepsi
Bad

Check the categories – Press Space Bar to continue

Coke
Good

Pepsi
Bad

Response key: E

Coke
Good

Pepsi
Bad

Response key: I

Coke
Good

Pepsi
Bad

terrible

Response key: I

Coke
Good

Pepsi
Bad

glory

Response key: E

Get set

```
install.packages("lme4")        ①
install.packages("ggplot2")     ②
library(lme4)                   ③
library(ggplot2)
```

① Installa il pacchetto per fittare i modelli lineari a effetti misti
② Installa il pacchetto i grafici
③ Rende disponibile i due paccheti

I dati

```
data = read.csv("data/example-data.csv",
                header = TRUE, sep =",")
head(data)
```

```
  respondent condition  stimuli accuracy latency
1          1 Whitegood     hate        1    1224
2          1 Whitegood     bf14        1    5160
3          1 Whitegood laughter        1    1214
4          1 Whitegood     bf56        1    1143
5          1 Whitegood     evil        1     827
6          1 Whitegood      wf3        1    1859
```

Numero di trial $\times$ condizione $\times$ soggetto:

```
table(data$respondent, data$condition)
```

```
     Whitebad Whitegood
  1        60        60
  2        60        60
  3        60        60
  4        60        60
  5        60        60
  6        60        60
....
```

Modello 1: $y_i = logit^{-1}(\alpha + \beta_c X_c + \alpha_{p[i]} + \alpha_{s[i]})$

```
accuracy1 = glmer(accuracy ~ 0 + condition + (1|stimuli) + (1|respondent),
                  data = data,
                  family = "binomial")
```

Modello 2: $y_i = logit^{-1}(\alpha + \beta_c X_c + \alpha_{p[i]} + \beta_{s[i]} c_i)$

```
accuracy2 = glmer(accuracy ~ 0 + condition + (0 + condition|stimuli) +
                    (1|respondent),
                  data = data,
                  family = "binomial")
```

Modello 3: $y_i = logit^{-1}(\alpha + \beta_c X_c + \alpha_{s[i]} + \beta_{p[i]} c_i)$

```
accuracy3 = glmer(accuracy ~ 0 + condition + (1|stimuli) +
                    (0 + condition|respondent),
                  data = data,
                  family = "binomial")
```

LMMs per i log-tempi

Modello 1: $y_i = \alpha + \beta_c X_c + \alpha_{p[i]} + \alpha_{s[i]} + \varepsilon_i$

```
logtime1 = lmer(log(latency) ~ 0 + condition + (1|stimuli) + (1|respondent),
                data = data,
                REML = FALSE)
```

Modello 2: $y_i = \alpha + \beta_c X_c + \alpha_{p[i]} + \beta_{s[i]} c_i + \varepsilon_i$

```
logtime2 = lmer(log(latency) ~ 0 + condition + (0 + condition|stimuli) +
                  (1|respondent),
                data = data,
                REML = FALSE)
```

Modello 3: $y_i = \alpha + \beta_c X_c + \alpha_{s[i]} + \beta_{p[i]} c_i + \varepsilon_i$

```
logtime3 = lmer(log(latency) ~ 0 + condition + (1|stimuli) +
                  (0 + condition|respondent),
                data = data,
                REML = FALSE)
```

GLMMs

Attenzione!

La funzione anova() viene usata solo perché è comoda, ma non si può fare realmente ANOVA tra il modello 2 e il modello 3

```r
anova(accuracy1, accuracy2, accuracy3)
```

```
Data: data
Models:
accuracy1: accuracy ~ 0 + condition + (1 | stimuli) + (1 | respondent)
accuracy2: accuracy ~ 0 + condition + (0 + condition | stimuli) + (1 | respondent)
accuracy3: accuracy ~ 0 + condition + (1 | stimuli) + (0 + condition | respondent)
          npar    AIC    BIC  logLik -2*log(L)  Chisq Df Pr(>Chisq)
accuracy1    4 4144.3 4172.1 -2068.1    4136.3
accuracy2    6 4141.3 4183.1 -2064.7    4129.3 6.9271  2    0.03132 *
accuracy3    6 4145.2 4187.0 -2066.6    4133.2 0.0000  0
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

LMMs

Attenzione!

La funzione anova() viene usata solo perché è comoda, ma non si può fare realmente ANOVA tra il modello 2 e il modello 3

```r
anova(logtime1, logtime2, logtime3)
```

```
Data: data
Models:
logtime1: log(latency) ~ 0 + condition + (1 | stimuli) + (1 | respondent)
logtime2: log(latency) ~ 0 + condition + (0 + condition | stimuli) + (1 | respondent)
logtime3: log(latency) ~ 0 + condition + (1 | stimuli) + (0 + condition | respondent)
         npar    AIC    BIC  logLik -2*log(L)   Chisq Df Pr(>Chisq)
logtime1    5 6073.2 6108.0 -3031.6    6063.2
logtime2    7 6061.4 6110.2 -3023.7    6047.4  15.743  2  0.0003815 ***
logtime3    7 5657.2 5705.9 -2821.6    5643.2 404.249  0
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

I modelli utili

GLMMs
Modello 2
θ_p
b_{WGBB} e b_{BGWB}

L'effetto IAT sembra essere maggiormente dovuto alle variazioni nel *funzionamento degli stimoli* tra le condizioni, mentre la performance dei soggetti sembra essere non alterata

LMMs
Model 3
τ_{WGBB} e τ_{BGWB}
δ_s

L'effetto IAT sembra maggiormente dovuto alle variazioni nella *performance dei soggetti* tra le condizioni, mentre il funzionamento degli stimoli sembra non essere affetto

I risultati andrebbero interpretati insieme!

Rasch-like estimates

θ_p

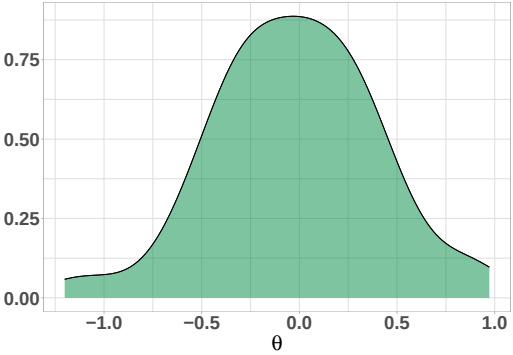

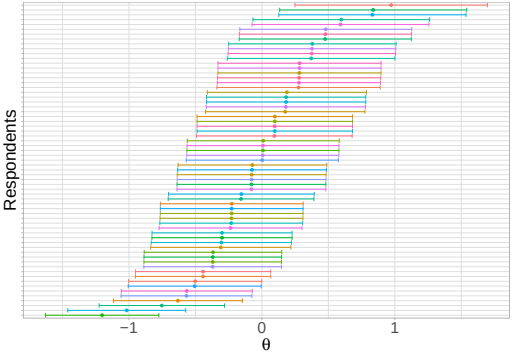

Codice - Distribuzione abilità

```
ab_iat =  as.data.frame(ranef(accuracy2,   # BLUP of the stimuli
                              condVar = TRUE))
ab_iatSingles = ab_iat[ab_iat$grpvar %in% "respondent",
                       c("grpvar", "condval", "condsd")]

ab_iat = data.frame(sbj = rownames(coef(accuracy2)$respondent),
                    theta = coef(accuracy2)$respondent[,1])
# density ability ----
ggplot(ab_iat,
                         aes(x = theta)) +
  geom_density()  +
  geom_density(fill = "springgreen4",
               alpha = .50) +
  theme_light() +
  theme(legend.position =  "none",
        axis.title.y = element_blank(),
        axis.title.x = element_text(size = 30, face = "bold"),
        axis.text = element_text(size = 26, face = "bold")) +
  xlab(expression(theta))
```

Codice - Differenze individuali abilità

```
ab_iatSingles$grpvar = paste(ab_iatSingles$grpvar, 1:nrow(ab_iatSingles), sep = "_'
ggplot(ab_iatSingles,
       aes(y = reorder(grpvar, condval),
           x = condval, color = grpvar)) + geom_point() +
  ylab("Respondents")  +theme_light() +
  theme(legend.position =  "none",
        axis.text.y = element_blank(),
        axis.title = element_text(size = 24),
        axis.text.x = element_text(size = 22)) +  geom_errorbarh(aes(xmin = condval
  xlab(expression(theta)) + scale_fill_manual(values = rainbow(65))
```

b_{WGBB} e b_{WGBB}

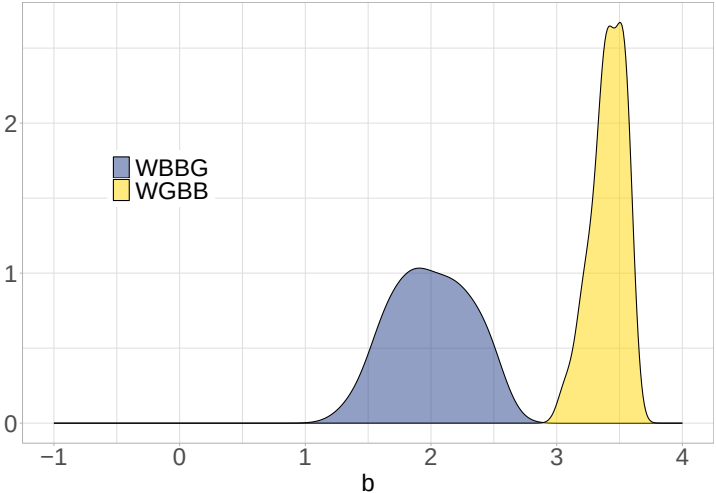

Codice distribuzioni facilità

```
ggplot(easiness_iat,
       aes(x = b,fill = Condition)) + geom_density(alpha =.50) +
  xlim(-1, 4) +
  scale_fill_manual(values = c("royalblue4", "gold"),
                    labels = c("WBBG", "WGBB")) +
  theme_light() +
  theme(legend.position = "inside",
        legend.position.inside = c(.2, .6),
        legend.title = element_blank(),
        axis.title.x = element_text(size = 24),
        axis.title.y = element_blank(),
        axis.text = element_text(size = 24),
        legend.text = element_text(size = 24))
```

Rasch-like estimates

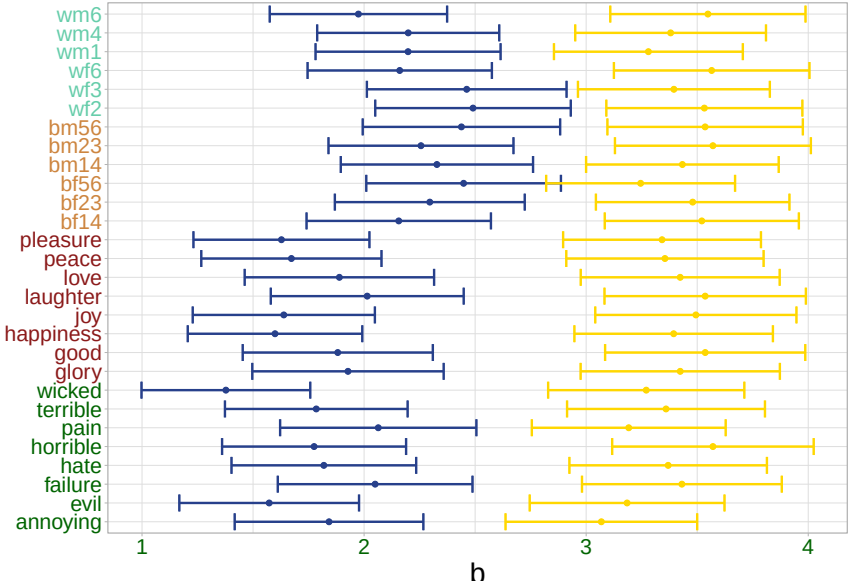

Codice stime facilità

```
easiness_iat$stimuli = as.character(easiness_iat$stimuli)
easiness_iat$b = with(easiness_iat, fix.est + blup)
easiness_iat$categoria <- sapply(easiness_iat$stimuli, categorizza)
cat_levels <- c("negative", "positive", "bp", "wp")
easiness_iat$categoria <- factor(easiness_iat$categoria, levels = cat_levels)
easiness_iat <- easiness_iat[order(easiness_iat$categoria, easiness_iat$stimuli), ]
easiness_iat$stimuli <- factor(easiness_iat$stimuli, levels = unique(easiness_iat$s
# graphs stimuli ----
graph_b_ci = ggplot(easiness_iat,
                    aes(x = b,
                        y = stimuli,
                        color = Condition)) +
  geom_point() +
  geom_errorbarh(aes(xmin = b - 1.96*se,
                     xmax= b + 1.96*se))
```

Log-normal estimates

$\tau_{\mathbf{WGBB}}$ e $\tau_{\mathbf{BGWB}}$

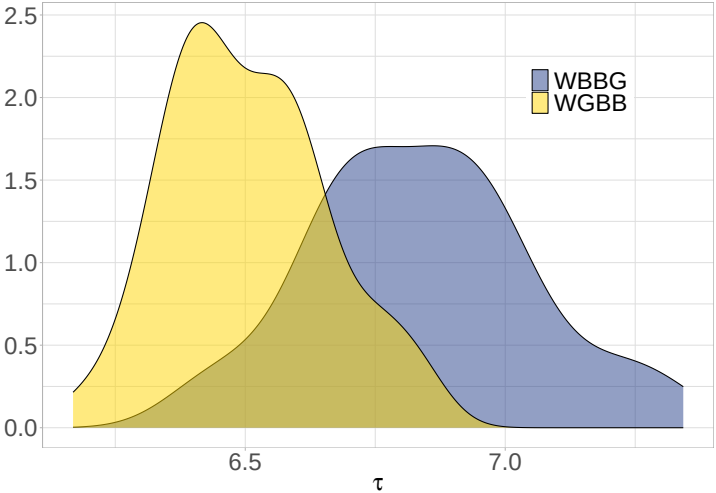

Codice distribuzioni velocità per condizione

```
speed = as.data.frame(ranef(logtime3), condvar= TRUE)
fixef_speed = data.frame(term = names(fixef(logtime3)),
                         est = (fixef(logtime3)))
speed = merge(speed, fixef_speed)
speed$tau = speed$condval + speed$est
# graph density ----
ggplot(speed,
       (aes(x = tau, fill  = term))) + geom_density(alpha = .5)  +
  theme_light()+
  scale_fill_manual(values = c("royalblue4", "gold"),
                    labels = c("WBBG", "WGBB")) +
  xlab(expression(tau)) +theme(legend.position = "inside",
                               legend.position.inside = c(.8, .8),
                               legend.title = element_blank(),
                               axis.title.x = element_text(size = 24),
                               axis.title.y = element_blank(),
                               axis.text = element_text(size = 24),
                               legend.text = element_text(size = 24))
```

Log-normal estimates

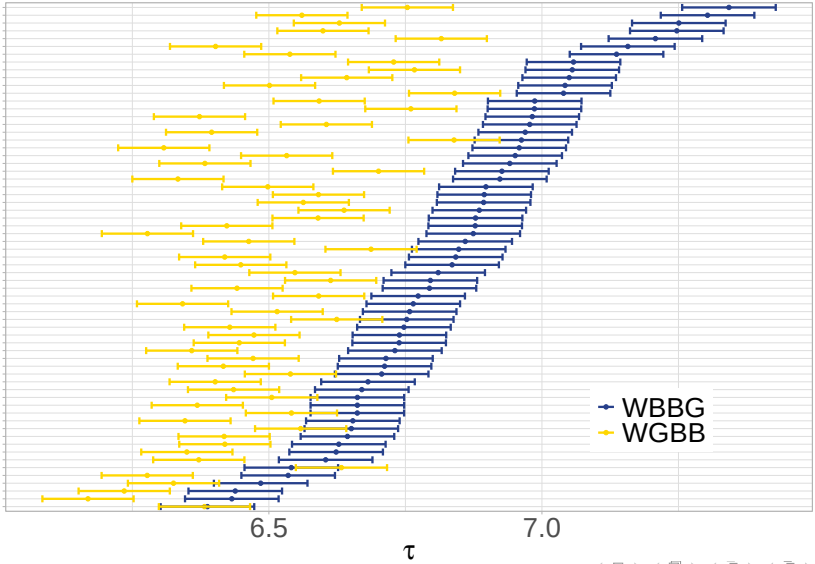

Codice differenze individuali velocità

```
ggplot(speed,
       (aes(x = tau, y = grp, color  = term))) + geom_point()  +
  theme_light()+
  scale_color_manual(values = c("royalblue4", "gold"),
                     labels = c("WBBG", "WGBB")) +
  xlab(expression(tau)) +theme(legend.position = "inside",
                               legend.position.inside = c(.8, .18),
                               legend.title = element_blank(),
                               axis.title.x = element_text(size = 24),
                               axis.title.y = element_blank(),
                               axis.text.x = element_text(size = 24),
                               axis.text.y = element_blank(),
                               legend.text = element_text(size = 24)) +
  geom_errorbar(aes(xmin = tau - 1.96*condsd, xmax = tau + 1.96*condsd),
                linewidth=.95)
```

Log-normal estimates

δ_s

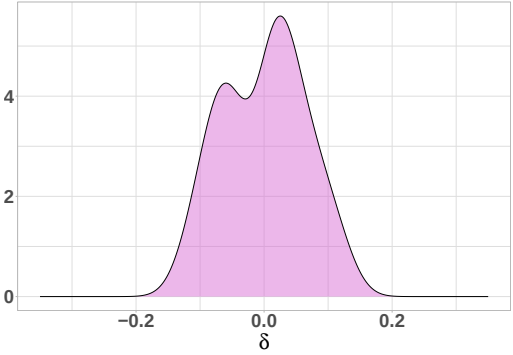

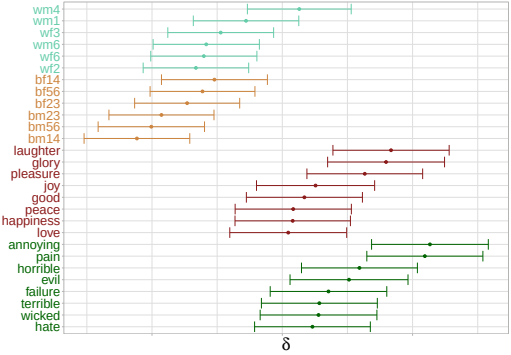

Codice parametri time intensity

```
intensity = as.data.frame(ranef(logtime3), condvar = TRUE)
intensity = intensity[intensity$grpvar %in% "stimuli", ]
colnames(intensity)[3] = "stimuli"
intensity$categoria <- sapply(intensity$stimuli, categorizza)
cat_levels <- c("negative", "positive", "bp", "wp")
intensity$categoria <- factor(intensity$categoria, levels = cat_levels)
intensity <- intensity[order(intensity$categoria, intensity$stimuli), ]

intensity$stimuli <- factor(intensity$stimuli, levels = unique(intensity$stimuli))

ggplot(intensity,
       aes(x = condval, y = stimuli, col = categoria)) + geom_point() +
  geom_errorbar(aes(xmin = condval - 1.96*condsd,
                    xmax= condval + 1.96*condsd)) +
  theme_light()
```

Log-normal estimates

AMERICAN PSYCHOLOGICAL ASSOCIATION

Psychological Methods

© 2024 American Psychological Association
ISSN: 1082-989X

https://doi.org/10.1037/met0000708

A Guided Tutorial on Linear Mixed-Effects Models for the Analysis of Accuracies and Response Times in Experiments With Fully Crossed Design

Ottavia M. Epifania, Pasquale Anselmi, and Egidio Robusto
Department of Philosophy, Sociology, Education and Applied Psychology, University of Padova

https://doi.org/10.1037/met0000708

Esercizio

Scaruicare i dati IAT dal sito del corso e provare ad analizzarli con l'approccio misto presentato (sia accuratezze sia tempi)

Calcolare anche uno scoring classico e confrontarlo con le stime dei soggetti ottenute dai tempi di risposta